无监督机器学习异常检测技术在智能监控领域的应用展望

中国农业银行研发中心上海研发部　陈婧　徐佳琦　李心玥　杨熠

摘　要：本文针对智能运维（AIOps）中的应用关键性能监控指标异常检测任务，基于孤立森林和深度神经网络两种常用的异常检测无监督机器学习方法进行了离线算法工程实践，以验证异常检测特征提取方法、机器学习离线算法模型，并结合农业银行正在建设的智能运维平台流处理智能告警系统展望了应用前景，以期为研发人员日后开展智能运维平台建设提供可行的借鉴和参考。

关键词：异常检测；孤立森林；深度神经网络；流处理智能告警系统

一、智能化运维的趋势和背景

从发展历程来看，商业银行的运维保障工作大致可分为三个发展阶段，即由最早期的手工运维，到目前普遍推广的自动化运维（DevOps），再到未来希望实现的智能化运维（AIOps）。实际上，当前自动化运维仍停留在“基于人为定义规则”的初级阶段，并且在后续根因分析上仍会采用人工跟踪分析的方法。但是，在银行应用系统不断增多、监控数据迅速膨胀的客观现实下，这种依赖运维专家总结规则配置告警阈值的方式逐渐变得力不从心，尤其在大规模的运维场景下显得效率很低。以农业银行的智能运维平台为例，目前传统应用性能指标异常检测监控系统通常依赖于运维人员经验，即事前预先人工配置固定的性能指标告警阈值，当采集到的性能指标数据超出一定阈值范围则触发告警。

与之相比，智能化运维建设强调通过机器学习算法自动地从海量运维数据中不断地学习并自主提炼总结规则，从而减少人工干预成本，提高运维效率。实践中，

应用系统性能指标的异常检测是智能化运维的一项底层核心技术，包括应用容量预测、故障根因分析等在内的一系列智能运维分析技术，都依赖于应用性能异常检测的结果。为此，本文重点介绍了针对应用系统性能指标数据进行离线智能分析的方法，以及如何将离线训练得到的异常检测机器学习模型作为智能监控系统中的重要环节，以提升应用监控告警的准确率，降低传统人工配置告警处置规则的人力成本，从而使运维工作应用告警响应得更加及时、高效。

二、基于无监督机器学习算法的异常检测工程实例

1. 应用性能指标异常检测任务概述

一般情况下，运维人员是通过监控多样的应用关键性能指标（KPI）来判断系统是否正常运行，监控的内容包含交易量、平均响应时间、网页访问量等服务型KPI，或 CPU 使用率、内存使用率等反应服务器健康状态的 KPI 等。在此模式下，当 KPI 呈现出不符合历史数据规律的突增、突降、抖动等异常时，往往意味着与其相关的应用发生了一些潜在故障，比如网络故障、数据库异常、配置错误、缺陷版本上线、服务器过载、外部攻击等。

目前，采用传统的人工告警阈值配置方法对持续稳定型性能数据有一定的成效，但告警阈值手工配置不仅开发项目组工作量大，且针对周期性及不规则型应用性能数据，人工规则配置方式告警效果较弱。针对这一问题，结合机器学习方法高效、准确地进行应用性能异常检测，自动预测 KPI 告警阈值，将可有效提高运维水平，保障系统持续提供稳定、可靠的服务。

2. 异常检测技术分类及原理简析

（1）全监督异常检测

全监督异常检测所用的训练集数据会分别被打上正确和异常标签，算法会根据训练集中的标签来建立预测模型，并读取未知类别的数据样本输出正确或异常标签。但是，由于实际工程实践中很难获得高质量的训练集，人工标记训练集的过程将消耗大量的人力成本，因此全监督异常检测的可应用范围很窄。

（2）半监督异常检测

半监督异常检测所用的训练集只会为正常数据样本打上标签，即半监督异常检测会根据正常数据建立一个“正常”模型，并将数据样本与“正常”模型的偏差定义为异常度。如果异常度超出了某个阈值，则产生报警信号；否则，判定为正常。但是，半监督异常检测面临着与全监督异常检测同样的难题，即难以获得打好标签的高质量训练数据集，因此在工程实践中往往也较难得到应用。

（3）无监督异常检测

无监督异常检测通常是基于正常样本和异常样本的特征有明显不同，而且正常样本的数目要远远多于异常样本的假设，考虑实际情况中系统监控性能指标的正常情况远远多于异常情况，所以这个假设是相对比较合理的。同时，该假设也大大降低了无监督异常检测的应用门槛，使其成为最常见的异常检测方式。

3. 数据集及工程任务描述

实践中，本文选取农业银行智能运维平台采集的“新一代核心银行系统 BoEing”4 日内的 60 秒交易量性能指标监控数据进行了算法工程实验，结合历史异常告警记录，选取“全国”“湖北省”“湖南省”“安徽省”“河南省”共 5 个维度的 BoEing 系统 60 秒交易量性能指标构建了异常检测数据集，共收集了 28 795 条样本数据，同时将前两日数据作为训练集，后两日数据作为测试集。在具体的工程实践中，研究人员根据训练集数据生成了机器学习模型，并对测试集数据进行了异常检测，对每个测试数据点均进行了异常标注。

采集到的交易量性能指标监控数据通过预处理，构建形成了异常检测数据集，其中包含了 TIMESTAMP、

KPI ID、KPI VALUE、LABEL4 列属性，以及 5759 个不同时间戳，且每个时间戳之间间隔为 60 秒。同时，数据集中每一个时刻共包含 5 个省市维度的 BoEing 系统 60 秒交易量性能指标数据，当对每一个时间戳进行一次异常检测，均会依据历史告警信息进行标注，并将严重及主要告警时刻前后五个时间戳对应的性能指标样本标注为 1（异常），其余无告警时刻样本则标注为 0（正常），最终再针对测试集通过模型预测输出异常判定结果。

4. 数据预处理

鉴于实例中使用的数据包含了多个维度交易量指标的时间序列信息，存在正负样本不均等问题，因此为执行时间序列异常检测，研究人员分两步对时间序列数据进行了预处理操作。第一步是依据 KPI ID 提取了 5 个维度 60 秒交易量指标的时间序列数据，即首先使用 Python Numpy 库获取了性能指标时间序列，并通过 KPI ID 获取了每个维度交易量性能指标的时间序列集合及对应标签集合。第二步是完成了时间序列数据标准化，即使用 Scikit-learn 库中提供的线性归一化函数对数据进行了标准化处理，使性能指标处于同一数量级，以便于进行综合对比。

5. 时间序列数据特征提取

在数据挖掘过程中，特征提取是极为重要且关键的一步，数据特征提取的好坏会影响机器学习模型异常检测的效果。为此，本文结合上述预处理结果，进一步进行了数据特征提取，以使可用于异常检测分类的信息更为丰富。实践中，基于数据 SARIMA 残差、简单指数平滑残差（Simple Exponential Smoothing）、二次指数平滑残差（Holt's Linear Trend Method）、三次指数平滑残差（Holt-Winters' Additive Method），以及滑动窗口均值、差值等统计方法，研究人员共选取了 21 个统计特征。同时，研究人员还使用过采样（Over Sample）的方法对数据池中的异常数据进行了多次抽样，生成了可最终用于模型的数据集合，以进一步提高异常检测性能。

6. 模型训练及测试

在模型训练及预测方面，本实例使用了 2 种无监督机器学习方法进行训练。第一种是结合孤立森林算法，采用了 Scikit-learn 中的 Isolation Forest 模型对训练集进行预测，并使用 Fit() 函数在预处理后的训练集上训练模型，最后在测试集上使用了 Predict() 方法来预测测试样本是否异常。第二种是结合深度神经网络算法，基于 Keras 框架进行的 DNN 模型训练，主要由输入层、隐藏层、输出层和 Sigmod 函数组成。其中，输入层由神经元对应数据输入特征数组成；隐藏层有两层，每层分别有 1024 和 256 个神经元；输出层由 1 个神经元加 Sigmod 函数组成，对应表示异常检测输出的类别 1（异常）或 0（正常），每次训练批数为 250，迭代训练集训练 200 轮后结果准确率可达 90% 以上。

7. 异常检测结果评估

实例中采用的异常检测正确率评估方法如下：如果模型在某一异常连续区间开始之后不晚于十个时间戳内检测到了该连续异常区间，则将该异常区间内所有异常点都算作一次正确预测正样本（True Positive，TP），否则该连续异常区间内每一个异常点都算作一次错误预测负样本（False Negative，FN）；如果算法将一个没有标记异常的时间点检测成异常，则算作一次错误预测正样本（False Positive，FP），否则记作一次正确预测负样本（True Negative，TN），最终评估指标为 f-score。

具体计算公式如下：

$$\mathrm{Pr}ecision = \frac{TP}{TP+FP}，\quad \mathrm{Re}call = \frac{TP}{TP+FN}$$

$$\mathrm{f}\text{-}score = \frac{2*\mathrm{Pr}ecision*\mathrm{Re}call}{\mathrm{Pr}ecision+\mathrm{Re}call}$$

结果显示，孤立森林算法测试集异常检测结果 f-score 值为 0.632，DNN 算法异常检测 f-score 值为

0.726。比较可知，DNN 算法模型结果的精度和召回率均较高，即异常检测的结果较为准确。具体来说，由于性能指标一般具有波动性、周期性，且异常点经常处于某一局部周期性检测数据中，导致其在处理局部性能指标异常时表现不佳，虽然孤立森林算法对全局异常点较为敏感，但 DNN 算法整体模型泛化能力及异常检测效果更优。

三、异常检测技术在农业银行运维领域应用展望

近年来，农业银行应用运维团队积极践行“主动运维”理念，将 DevOps 思想应用于实际运维工作中，并不断探索发展 AIOps 智能运维之路。例如，农业银行智能运维平台监控中心在智能分析的技术架构上，将场景、算法、数据三者结合起来，进行了性能重构和智能监控功能优化。目前，农业银行智能运维平台监控中心在已有旁路监控、日志监控、业务组件性能指标监控的基础上，基于实践中沉淀的运维数据采集、处理及分析经验，正着手优化重构一套流处理应用智能异常告警系统，流处理应用智能异常告警系统架构如图 1 所示。

流处理应用智能异常告警系统针对特定的运维场景，从监控的时间序列数据出发，可对数据进行相应的预处理，并基于离线机器学习训练分析生成模型，将实时数据通过流计算模块加工成深度学习算法模型的可训练特征，再送入到离线训练生成的机器学习模型中进行相应的预测。流处理应用智能异常告警系统数据流如图 2 所示。

图 1　流处理应用智能异常告警系统架构

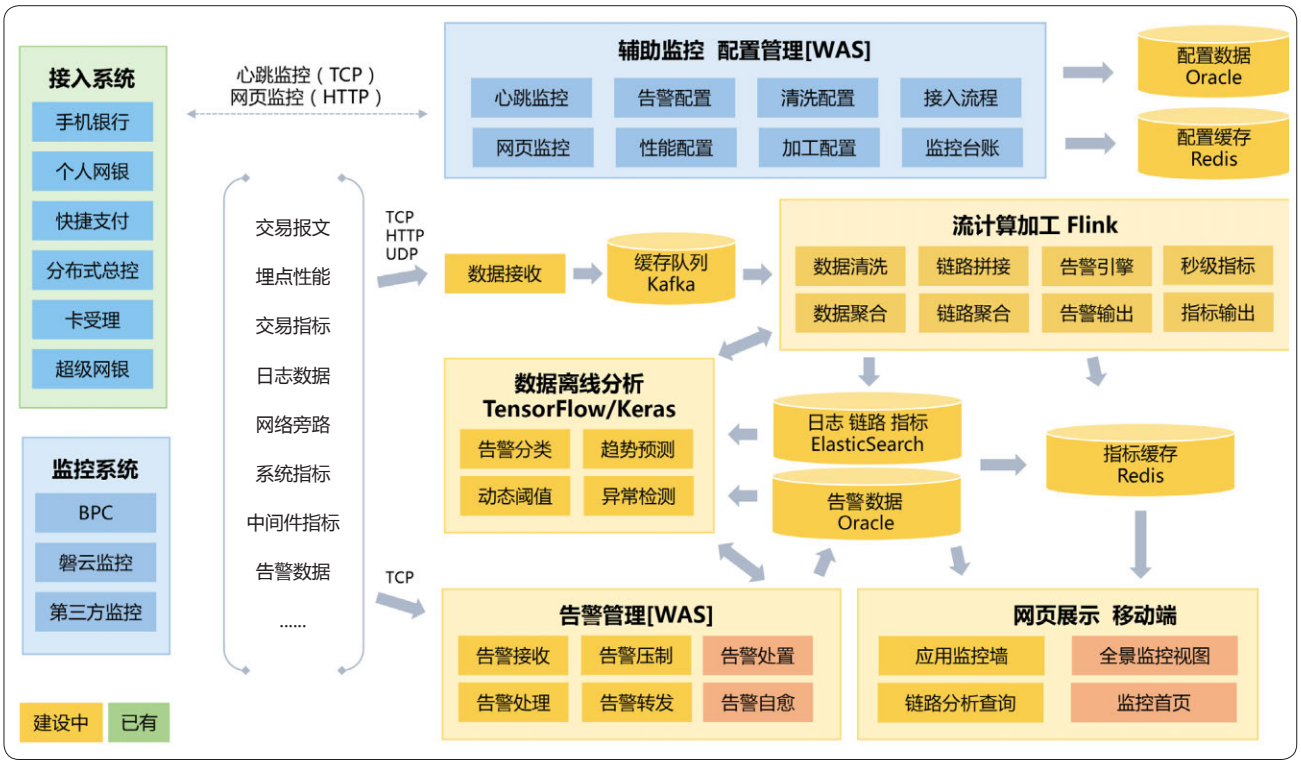

图 2 流处理应用智能异常告警系统数据流

在数据离线分析模块中，前文所介绍的时间序列性能数据特征提取方法、模型搭建训练方式均可迁移融合应用于异常检测智能运维场景。此时，流处理应用智能异常告警系统将采用定时作业的方式，每天根据历史数据生成离线分析模型并存到 ElasticSearch 的相应配置库中，存储格式采取 PB 文件的形式。在流计算指标加工 Flink 模块中，通过对性能数据进行数据提取和计算信息装配，并在窗口期聚合实现流式累计型计算，可实现对指标的多维度、多指标、多窗口期的实时计算，农业银行智能运维平台监控中心流计算框架如图 3 所示。

在实际应用中，流计算模块和离线机器学习模块首先会通过 Flink 作业读取 ElasticSearch 上存储的 PB 模型文件；然后利用 Tensorflow/Keras 框架将所有读取到的 PB 文件还原成之前训练好的神经网络模型，用于深度学习的预测；最后所有的 PB 模型都将通过 Flink 程序的 Driver 组件统一生成，再向下分发至各个 Executor，预测过程将在各个 Job 中执行。在此基础上，为保证实时数据处理过程中数据的快速存取，流处理应用智能异常警告系统采用了 Redis 作为临时存储，可分别存储根据机器学习算法生成的预测值、Flink 加工生成的真实指标和提前生成的 PB 预测模型。

在智能分析预测过程中，首先需要积累足够的初始数据到真实指标队列，当积累了 10 分钟的数据后，即可将 PB 模型队列中的数据填入 PB 模型中，预测下一分钟的数据，并将下一分钟的预测值填入到预测队列中，通过真实值和预测值的比较，最终判断是否产生告警。与传统的人工告警规则配置方式相比，上述方法能有效地改善现有运维系统中存在的告警粒度较为粗糙以及漏告警、误告警较多等问题，不仅可以大幅度降低手动配置阈值的人力成本，同时也有助于提升监控系统的自适

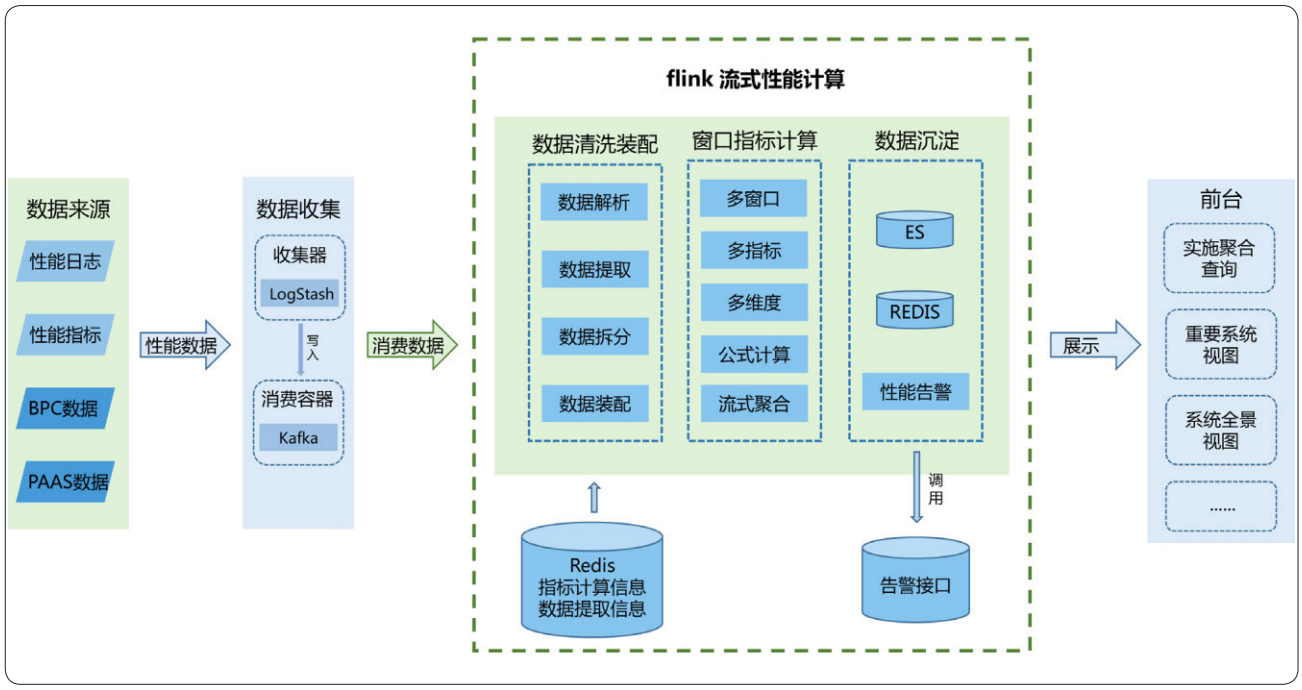

图 3　农业银行智能运维平台监控中心流计算框架

应能力，保障应用异常检测告警的准确性。

本文简单介绍了两种工业界常用的异常检测无监督机器学习算法原理，以及基于开源工具库的算法工程实验过程，以期为智能运维系统研发人员提供理论落地的可行参考，以及为银行探索智能应用性能监控异常检测任务提供基于工程实践的解决思路。FCC

参考文献：

[1] Liu D, Zhao Y, Xu H, et al. Opprentice: Towards practical and automatic anomaly detection through machine learning[C]. Proceedings of the 2015 Internet Measurement Conference. New York：ACM Press， 2015:211–224.

[2] Liu F T, Ting K M, Zhou Z H. Isolation forest[C]. 2008 Eighth IEEE International Conference on Data Mining.New York：IEEE Press，2008: 413–422.

[3] Yasin. 深度神经网络总结 .（2019–01–09）[2020–04–15]. https://blog.csdn.net/Yasin0/article/details/86167009.

公　示

根据国家新闻出版署《关于开展 2020 年度新闻记者证核验工作的通知》（国新出发函〔2021〕1 号）、《新闻记者证管理办法》、《关于期刊申领新闻记者证的有关通知》等文件要求，我单位已对持有新闻记者证人员的资格进行严格审核，现将持有新闻记者证的人员名单公示如下：焦卢玲、李勇。公示期截至 2021 年 2 月 20 日。

举报电话：010–83138953，010–51915111 转 805。

《中国金融电脑》杂志社

2021 年 2 月